

TRƯỜNG ĐẠI HỌC NGOẠI NGỮ - TIN HỌC TP. HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN

KHÓA LUẬN TỐT NGHIỆP

**TÌM HIỂU MÔ HÌNH NGÔN NGỮ LỚN
TIẾNG ANH VÀ ỨNG DỤNG TRONG
VIỆC PHÁT HIỆN TIN GIẢ**

GIẢNG VIÊN HƯỚNG DẪN: TS. Trần Khải Thiện
SINH VIÊN THỰC HIỆN: Lê Huỳnh Nghiêm

TP. HỒ CHÍ MINH – THÁNG 7 NĂM 2024

TRƯỜNG ĐẠI HỌC NGOẠI NGỮ - TIN HỌC TP. HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN

KHÓA LUẬN TỐT NGHIỆP

**TÌM HIỂU MÔ HÌNH NGÔN NGỮ LỚN
TIẾNG ANH VÀ ỨNG DỤNG TRONG
VIỆC PHÂN LOẠI TIN GIẢ**

GIẢNG VIÊN HƯỚNG DẪN: TS. Trần Khải Thiện
SINH VIÊN THỰC HIỆN:

TP. HỒ CHÍ MINH – THÁNG 7 NĂM 2024

LỜI CẢM ƠN

Trước hết, chúng tôi xin gửi lời cảm ơn sâu sắc nhất đến thầy TS. Trần Khải Thiện, người thầy đã phổ cập giúp chúng tôi chọn được đề tài này, định hình hướng nghiên cứu, tận tình hướng dẫn và hỗ trợ chúng tôi trong suốt quá trình thực hiện luận văn tốt nghiệp

Chúng tôi xin gửi lời cảm ơn chân thành đến quý thầy, cô trong trường Đại học Ngoại ngữ - Tin học thành phố Hồ Chí Minh. Các thầy, cô đã chỉ dạy và truyền đạt cho chúng tôi rất nhiều kiến thức, tạo nên nền tảng vững chắc để chúng tôi có cơ hội được tiếp thu, học hỏi và thực hiện tốt khóa luận một cách tốt nhất.

Tôi xin chân thành cảm ơn các Thầy/Cô trong Hội đồng đánh giá khóa luận tốt nghiệp đã đóng góp ý kiến quý báu giúp chúng tôi hoàn thiện khóa luận.

TP. Hồ Chí Minh, Tháng 7 Năm 2024

Lê Huỳnh NghiêM – 21DH114462

LỜI CAM ĐOAN

Chúng tôi, Lê Huỳnh Nghiêm – MSSV: 21DH114462, xin cam đoan đây hoàn toàn là bài luận văn được hoàn thiện dựa trên quá trình nghiên cứu và làm việc của riêng chúng tôi, dưới sự hướng dẫn của TS. Trần Khải Thiện.

Chúng tôi xin cam đoan, toàn bộ kiến thức được trình bày trong bài nghiên cứu đều là do chúng tôi tìm hiểu, nghiên cứu và trình bày lại, mọi tài liệu tham khảo đều được trích dẫn nguồn rõ ràng và chi tiết.

Kết quả từ quá trình nghiên cứu đều là của riêng chúng tôi, không có sự sao chép từ bất kì công trình nào khác bên ngoài. Chúng tôi xin hoàn toàn chịu trách nhiệm đối với những điều chúng tôi không trung thực.

TP. Hồ Chí Minh, Tháng 7 Năm 2024

Lê Huỳnh Nghiêm – 21DH114462

MỤC LỤC

MỤC LỤC	i
DANH MỤC TỪ VIẾT TẮT	iii
DANH MỤC BẢNG	iv
DANH MỤC HÌNH ẢNH	v
CHƯƠNG I. MỞ ĐẦU	1
1. Lý do chọn đề tài	1
2. Mục tiêu của đề tài	1
3. Đối tượng nghiên cứu	1
4. Phạm vi nghiên cứu và giới hạn đề tài	1
5. Đóng góp của đề tài	2
5.1. Đóng góp về khoa học	2
5.2. Đóng góp thực tiễn	2
6. Kết cấu khóa luận	2
CHƯƠNG II. CƠ SỞ LÝ THUYẾT VÀ CÔNG TRÌNH LIÊN QUAN	4
1. Tổng quan	4
2. Mô hình ngôn ngữ lớn	4
2.1. Kiến trúc Transformer	4
2.2. Pre-training và các mô hình ngôn ngữ lớn dựa trên Transformer	6
2.3. Mô hình BERT	7
2.4. Mô hình GPT	7
2.5. In-context learning và Chain-of-Thought	7
2.6. Mô hình ngôn ngữ lớn và ứng dụng	8
3. Bài toán phát hiện tin giả	8
CHƯƠNG III. ỨNG DỤNG MÔ HÌNH NGÔN NGỮ LỚN CHO BÀI TOÁN PHÁT HIỆN TIN GIẢ	9
1. Phân tích bài toán	9
2. Mô hình đề xuất	9
2.1. Thu thập Explanation	10

2.2.	Encoding và Representation	11
2.3.	Final Classification	11
3.	Đánh giá	12
3.1.	Cấu hình thực nghiệm	12
3.2.	Tập dữ liệu	12
3.3.	Các phương pháp khác tham gia đánh giá	13
3.4.	Các chỉ số đánh giá	13
3.5.	Kết quả thực nghiệm	14
3.6.	Đánh giá kết quả	14
CHƯƠNG IV. KẾT LUẬN		15
1.	Kết quả đạt được	15
2.	Hướng nghiên cứu tiếp theo	15
TÀI LIỆU THAM KHẢO		16

DANH MỤC TỪ VIẾT TẮT

VIẾT TẮT	ĐẦY ĐỦ
LLM	Large Language Model
AI	Artificial Intelligence
NLP	Natural Language Processing
GPT	Generative Pre-trained Transformer
BERT	Bidirectional Encoder Representations from Transformers
RNN	Recurrent Neural Network
GPU	Graphics Processing Unit
LSTM	Long Short-Term Memory
GRU	Gated Recurrent Unit
CNN	Convolutional Neural Network
CoT	Chain-of-thought
EGN	Explanation-Guided Network
MLP	Multilayer Perceptron

DANH MỤC BẢNG

Bảng 1. Thống kê thành phần tập dữ liệu GossipCop và COVID-19.....	13
Bảng 2. Kết quả thực nghiệm mô hình EGN trên tập dữ liệu GossipCop	14
Bảng 3. Kết quả thực nghiệm mô hình EGN trên tập dữ liệu COVID-19	14

DANH MỤC HÌNH ẢNH

Hình 1. Kiến trúc mô hình transformer [8]	5
Hình 2. Tổng quan cấu trúc của EGN	10

CHƯƠNG I. MỞ ĐẦU

1. Lý do chọn đề tài

Mô hình ngôn ngữ lớn (LLM) đã nổi lên như một bước đột phá trong lĩnh vực trí tuệ nhân tạo (AI) nói chung và xử lý ngôn ngữ tự nhiên (NLP) nói riêng. Với khả năng hiểu, xử lý và tạo ra văn bản tự nhiên, LLM đã và đang cách mạng hóa cách chúng ta tương tác với máy tính và dữ liệu, nhất là dữ liệu ngôn ngữ.

LLM có tiềm năng ứng dụng rộng lớn trong nhiều lĩnh vực, từ dịch thuật, tóm tắt văn bản, hỗ trợ sáng tạo nội dung, đến phát triển các hệ thống đối thoại tự động và trợ lý ảo thông minh. Sự phát triển của LLM không chỉ mang lại lợi ích cá nhân và doanh nghiệp, mà còn mở ra những cơ hội mới cho nghiên cứu và phát triển công nghệ.

2. Mục tiêu của đề tài

Đề tài này nhằm mục đích tìm hiểu sâu về LLM, từ kiến trúc, quá trình phát triển đến các ứng dụng thực tế. Cụ thể, đề tài sẽ tập trung vào các nội dung sau:

- Tổng quan về LLM: khái niệm, lịch sử phát triển, các kiến trúc phổ biến (Transformer, GPT, BERT...)
- Ứng dụng của LLM trong NLP: Xây dựng một mô hình dựa trên LLM trong bài toán tự động phát hiện tin giả.

3. Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là mô hình ngôn ngữ lớn tiếng Anh và ứng dụng của nó trong bài toán phát hiện tin giả.

4. Phạm vi nghiên cứu và giới hạn đề tài

Nghiên cứu này tập trung vào tìm hiểu một số mô hình ngôn ngữ state of the art và các phương pháp khai thác khả năng của nó. Nghiên cứu sẽ đánh giá hiệu quả của mô hình trong ứng dụng phát hiện tin giả trên các tập dữ liệu và so sánh với các công trình nghiên cứu trước đó.

Giới hạn của đề tài:

- **Phạm vi dữ liệu:** Đề tài sử dụng 2 bộ dữ liệu mang tính học thuật, được sử dụng rộng rãi ở các công trình nghiên cứu khác.
- **Ngôn ngữ:** Đề tài nghiên cứu các mô hình Tiếng Anh cũng như ứng dụng của nó trên tiếng Anh.

5. Đóng góp của đề tài

5.1. Đóng góp về khoa học

Khám phá và khai thác tối đa tiềm năng của LLM: Đề tài sẽ nghiên cứu các kỹ thuật khai thác tiềm năng của LLM như prompting, tinh chỉnh và suy luận – diễn giải. Qua đó nâng cao hiệu quả của LLM trong đa dạng tác vụ.

Phát triển một mô hình phát hiện tin giả tiên tiến dựa trên LLM: Dựa trên kết quả nghiên cứu, đề tài sẽ xây dựng một mô hình phát hiện tin giả hoàn toàn mới dựa trên LLM. Mục tiêu là tạo ra một mô hình phát hiện tin giả hiệu quả, có khả năng ứng dụng cao trong thực tế và đóng góp vào việc giải quyết vấn nạn tin giả hiện nay. Mô hình được đánh giá ngang hàng ở các hội thảo khoa học lớn.

5.2. Đóng góp thực tiễn

Cung cấp cái nhìn tổng quan về LLM: Đề tài sẽ cung cấp một cái nhìn tổng quan về LLM bao gồm kiến trúc, phương pháp huấn luyện và các ứng dụng tiềm năng. Điều này sẽ giúp các nhà phát triển, kỹ sư và những người quan tâm đến LLM hiểu rõ hơn về công nghệ này và áp dụng nó vào các lĩnh vực khác nhau.

Phát triển một công cụ hỗ trợ phát hiện tin giả: Bằng cách áp dụng LLM vào bài toán phát hiện tin giả, đề tài sẽ phát triển một công cụ có khả năng phân tích và đánh giá độ tin cậy của thông tin. Công cụ này có thể được tích hợp vào các hệ thống mạng xã hội, các hệ thống tài hoặc báo chí.

Thúc đẩy triển khai LLM vào các tác vụ khác: Bằng việc chứng minh tiềm năng của LLM trong bài toán phát hiện tin giả, nghiên cứu mở ra tiềm năng của nó trên các ứng dụng khác như phân loại tin tức, phân tích các văn bản thuộc các lĩnh vực riêng biệt như kinh tế tài chính, y khoa...

6. Kết cấu khóa luận

Nội dung của khóa luận được hoàn thiện và tổ chức với 4 chương:

❖ Chương I. Mở đầu

Giới thiệu tổng quan về công trình nghiên cứu với các vấn đề như lý do chọn đề tài, mục tiêu, đối tượng, phạm vi nghiên cứu và ý nghĩa của công trình.

❖ Chương II. Cơ sở lý thuyết và các công trình nghiên cứu liên quan

Trình bày các khái niệm thiết yếu của các thành phần chính được sử dụng trong công trình nghiên cứu. Tóm tắt nội dung từ các công trình nghiên cứu liên quan đã tham khảo về mô hình ngôn ngữ lớn và bài toán phát hiện tin giả.

❖ **Chương III. Ứng dụng mô hình ngôn ngữ lớn cho bài toán phát hiện tin giả**

Nêu rõ bài toán thực hiện, môi trường và công nghệ sử dụng để hiện thực. Đề xuất mô hình sử dụng và các thang đo đánh giá để có thể lựa chọn mô hình tốt nhất cho dữ liệu thực tế.

❖ **Chương IV. Kết luận**

Đưa ra các kết luận có được từ quá trình nghiên cứu và hiện thực, từ đó đề ra các hướng phát triển tiếp theo trong tương lai.

CHƯƠNG II. CƠ SỞ LÝ THUYẾT VÀ CÔNG TRÌNH LIÊN QUAN

1. Tổng quan

Mô hình RNN [1] kết hợp với cơ chế *attention* [2] được ứng dụng rất nhiều cho các bài toán *Sequence to Sequence* [3] và có được những kết quả khá tốt nhưng kiến trúc này vẫn còn tồn tại một số nhược điểm lớn:

- Một nút mạng RNN chỉ nhận được thông tin ngữ nghĩa từ các nút mạng trước đó (các từ nằm bên trái) mà thiếu thông tin của các từ nằm sau (các từ nằm bên phải). Tuy biến thể Bidirectional RNN [4] có thể phần nào giải quyết vấn đề này nhưng làm tăng thời gian tính toán trong khi thông tin vẫn truyền một cách gián tiếp.
- Mô hình tính toán một cách tuần tự: kết quả của lần tính toán hiện tại dựa vào kết quả của lần tính toán trước. Vì vậy, dữ liệu từ các lần truyền không thể thực hiện song song, dẫn đến việc không thể tận dụng được GPU.
- Có thể bị “quên” hoặc “mất mát” dữ liệu khi thông tin được truyền qua nhiều nút mạng trong quá trình tính toán do đạo hàm quá lớn hoặc quá bé (*vanishing / exploding gradient*) [5]. Điều này gây cản trở cho việc nhúng thông tin ngữ cảnh của các từ trong câu cho các vector biểu diễn từ. Mặc dù một số biến thể của RNN như *Long Short Turn Memory* (LSTM) [6] hoặc *Gated Recurrent Unit* (GRU) [7] có khả năng chọn lọc để quyết định giữ lại hay loại bỏ thông tin tại mỗi nút mạng, nhưng khi qua nhiều nút trung gian thì thông tin vẫn bị mất mát.

Để giải quyết các nhược điểm này, năm 2017, nhóm nghiên cứu của Google Brain đã giới thiệu mô hình Transformer [8]. Đây là một tiến bộ lớn trong lĩnh vực NLP là tiền đề của các mô hình ngôn ngữ lớn *state of the art* hiện tại.


2. Mô hình ngôn ngữ lớn

2.1. Kiến trúc Transformer

Năm 2017, Vaswasi và cộng sự đề xuất mô hình Transformer. Mô hình Transformer cung tuân theo kiến trúc *Encoder-Decoder* [9] nhưng với *Encoder* và *Decoder* được xây dựng như Hình 1. Ngoài trừ các module thường gặp trong các kiến trúc mạng nơ ron, *Transformer* giới thiệu 3 kỹ thuật mới:

- **Kỹ thuật scaled dot-product attention:** Đây là kỹ thuật cho phép Transformer thực hiện cơ chế *attention* theo 2 chiều và có khả năng thực hiện song song. Kỹ thuật này dùng trong các module *Self Attention*, *Masked Self Attention* và *Encoder-Decoder Attention* (hay *Cross Attention*).

- **Kỹ thuật multi-head:** Đây là kỹ thuật áp dụng *Self Attention* nhiều lần (mỗi lần thực hiện là một head) và tổng hợp kết quả, tương tự với cơ chế áp dụng nhiều kernel và tổng hợp kết quả của CNN [10]. Đây là cơ chế khiến *Transformer* có thể thực hiện tính toán song song.
- **Cơ chế positional encoding:** Cơ chế này cho phép encode thông tin vị trí vào các vector input.



Hình 1. Kiến trúc mô hình transformer [8]

a. Cấu trúc khối Encoder

Khối Encoder gồm $N = 6$ lớp giống nhau (*encoder layer*) xếp chồng lên nhau. Mỗi lớp được cấu tạo từ 2 lớp con (*sub-layer*): *multi-head self-attention* với chức năng nhúng ngữ nghĩa các từ xung quanh vào các véc-tơ biểu diễn từ và *fully connected feedforward network* với chức năng tính toán, rút trích thông tin. Trên Hình 1, hai lớp con này ứng với module *Self Attention*, trong đó hai kỹ thuật *multi-head* và *scaled*

dot-product attention sẽ được áp dụng cùng lúc, và module *FeedForward*. Đầu ra của mỗi lớp con này được áp dụng lớp *residual connection* [11] và *layer normalization* [12]: $LayerNorm(x + Sublayer(x))$ với mục đích hạn chế *vanishing gradient*, giảm *training error* và giảm thời gian huấn luyện. Để áp dụng *residual connection*, các lớp con của mô hình đều có đầu ra cùng kích thước $d_{model} = 512$. Trên Hình 1, module *Add & Norm* sẽ đảm nhận việc tính toán cho bước *residual* này.

b. Cấu trúc khối Decoder

Khối Decoder: gồm $N = 6$ lớp giống nhau (*decoder layer*) xếp chồng lên nhau. Bên cạnh 2 lớp con như *Encoder*, *Decoder* còn có thêm lớp con thứ 3 thực hiện attention với đầu ra của từng từ sau khi qua *encoder*. Lớp con này đóng vai trò lấy *vector context* và *align* giữa chuỗi nguồn và chuỗi đích như trong nghiên cứu của Bahdanau và cộng sự [2]. Lớp này tương ứng với module *Decoder-Encoder Attention*. Ngoài ra, ở module này, *Self-Attention* sẽ được biến chuyển thành *Masked Self-Attention*, trong đó Vaswani và cộng sự [8] tiến hành việc che thông tin masked để mô phỏng hành vi dự đoán (*predict*) của mô hình ngôn ngữ. Việc này sẽ khiến cho mô hình tránh lấy thông tin ngữ cảnh của các từ tương lai khi huấn luyện.

2.2. Pre-training và các mô hình ngôn ngữ lớn dựa trên Transformer

Huấn luyện sơ bộ (*pre-train*) [13] là một phương pháp nghiên cứu đã được nhiều thành công nhờ vào sự phát triển của các mô hình học sâu, sự hiện đại của phần cứng và sự bùng nổ của dữ liệu. Ý tưởng của phương pháp này là huấn luyện trước một kiến trúc mạng học sâu với một tập dữ liệu tổng quát. Mạng học sâu này, với bộ trọng số tổng quát thu được, sẽ tiếp tục được tinh chỉnh (*fine-tune*) hoặc học chuyển giao (*transfer learning*) cho các ứng dụng và bài toán cụ thể.

Kỹ thuật này thường được dùng để huấn luyện sơ bộ một mô hình ngôn ngữ để có thể được tinh chỉnh tiếp cho các tác vụ thể. Khi huấn luyện một mô hình ngôn ngữ với một kiến trúc mạng học sâu lớn và một kho dữ liệu lớn thì ta thu được một mô hình ngôn ngữ lớn (*large language model*).

Kể từ sự ra đời của mô hình Transformer, nhiều mô hình ngôn ngữ lớn được tạo ra dựa trên kiến trúc Transformer. Một số mô hình tiêu biểu có thể kể đến BERT dùng kiến trúc encoder của Transformer, họ mô hình GPT [14] dùng kiến trúc decoder của Transformer. Việc tận dụng các mô hình ngôn ngữ lớn vào các tác vụ cụ thể đã cho ra những kết quả ấn tượng trong lĩnh vực NLP.

Các mô hình ngôn ngữ lớn dựa trên Transformer có thể được chia thành 2 nhóm chính: *Auto Encoding* và *Auto Regression* [15]. Mô hình ngôn ngữ lớn theo hướng *Auto Encoding* sẽ mã hóa (*encode*) hay nhúng (*embed*) dữ liệu đầu vào để tạo thành

một dạng biểu diễn chứa thông tin ngữ nghĩa của dữ liệu. Trong khi đó *Auto Regression* sẽ hướng đến việc tạo ra một chuỗi đầu ra từ chuỗi đầu vào ban đầu. Ý nghĩa của chuỗi đầu ra tùy thuộc vào mục đích sử dụng và chiến lược huấn luyện. Tuy nhiên, một mô hình có thể có thể có 2 kiến trúc của *Transformer* và thực hiện được cả tất cả chức năng của cả 2 nhóm trên (T5 [16], Flan-T5 [17]).

2.3. Mô hình BERT

Năm 2018, Devlin và cộng sự đề xuất mô hình *Bidirectional Encoder Representations from Transformers (BERT)* [18]. BERT dùng chung một kiến trúc với khối *encoder* của *Transformer*. BERT được huấn luyện sơ bộ trên *BooksCorpus* [19] (800 triệu từ) và *English Wikipedia* (2,500 triệu từ). BERT được Google sử dụng để hiểu rõ các tìm kiếm của người dùng [20].

2.4. Mô hình GPT

Mô hình *Generative Pre-training Transformer (GPT)* [21] được phát triển bởi Open AI là một trong những mô hình học sâu *state of the art* hiện nay. Nếu BERT được phát triển dựa trên kiến trúc *Encoder* của *Transformer*, GPT sử dụng kiến trúc *Decoder* của *Transformer*.

Do dựa trên kiến trúc *Decoder* của *Transformer*, *in-context learning* [22] là một kỹ thuật được đề xuất để thực hiện tinh chỉnh mô hình GPT-3 [22]. Kỹ thuật này nhanh chóng trở thành tiêu chuẩn cho các LLM được thiết kế có bao gồm kiến trúc theo nhóm *Auto Regression*.

2.5. In-context learning và Chain-of-Thought

In-context learning là các kỹ thuật cho mô hình học các thực hiện tác vụ bằng các thao tác trực tiếp bằng văn bản đầu vào (*prompt*) mà không cần thay đổi các tham số của mô hình. *In-context learning* đã cho thấy hiệu suất ấn tượng trong các tác vụ cụ thể chỉ bằng cung cấp một vài điều kiện đơn giản thông qua các cặp đầu vào – nhãn (Các minh họa) [23]. *In-context learning* bao gồm:

- **Zero-shot learning:** Mô hình thực hiện tác vụ không có minh họa về tác vụ đó. Mô hình chỉ dựa vào các mô tả về tác vụ từ đầu vào và kiến thức đã học được từ quá trình huấn luyện trước đó để đưa ra câu trả lời.
- **One-shot learning:** Mô hình thực hiện tác vụ với một minh họa từ tác vụ đó. Mô hình sử dụng ví dụ này để hiểu yêu cầu của tác vụ và áp dụng kiến thức đã học từ quá trình huấn luyện để đưa ra câu trả lời.
- **Few-shot learning:** Mô hình thực hiện một tác vụ với một số lượng nhỏ các minh họa. Mô hình sử dụng các ví dụ này để điều chỉnh kiến thức đã học và cải thiện hiệu suất trên tác vụ cụ thể.

Đến năm đầu 2022, *Chain-of-thought (CoT)* [24] xuất hiện và tăng khả năng của *in-context learning* trong quá trình khai thác LLM. CoT cung cấp cho các LLM khả năng tạo ra một chuỗi suy nghĩ – một chuỗi các bước lập luận trung gian mạch lạc dẫn đến câu trả lời cuối cùng của vấn đề. *Chain-of-thought* triển khai một khả năng diễn giải mạnh mẽ từ thông qua các suy luận trung gian trên LLM.

Bên cạnh đó, *Zero-shot CoT* [25] cung cấp một cách tiếp cận khác dựa trên CoT nhưng đơn giản như *zero-shot learning*. *Zero-shot CoT Learning* được thực hiện tương tự như *zero-shot learning* và thêm một câu tương tự như: “*Let’s think step by step*”.

2.6. Mô hình ngôn ngữ lớn và ứng dụng

LLM được ứng dụng đa dạng trên các lĩnh vực khác nhau [26]:

- **Đối với cộng đồng học thuật:** LLM đã cách mạng hoá cách phát triển AI nên nó có tác động đáng kể đến cộng đồng học thuật. LLM có thể được dùng có các tác vụ NLP cổ điển, tham gia vào hệ thống truy hồi thông tin, tăng cường hệ thống *knowledge graph*, dùng LLM như một công cụ đánh giá mang tính học thuật và nhiều tác vụ khác.
- **Đối với các lĩnh vực đặc thù:** LLM tham gia vào đa dạng các lĩnh vực trong thực tế. Tiêu biểu như y tế, giáo dục, tài chính, hỗ trợ nghiên cứu khoa học và nhiều tác vụ khác.

3. Bài toán phát hiện tin giả

Việc lan truyền nhanh và rộng của tin giả online đã đe dọa thế giới thực trên các lĩnh vực quan trọng như chính trị [27], kinh tế [28] và sức khỏe cộng đồng [29]. Trong số các biện pháp đối phó để chống lại vấn đề này, tự động phát hiện tin giả, nhằm mục đích phân biệt tự động tin tức không chính xác và cố ý gây sự hiểu lầm với các tin tức khác, đã trở thành một biện pháp hứa hẹn trong thực tế [30].

Mặc dù có nhiều tiến bộ [31], việc hiểu và mô tả tin giả vẫn còn là thách thức. Điều này là do sự phức tạp của quá trình tạo tin giả: Người tạo tin giả có thể thao túng bất kỳ phần nào của tin tức, dùng đa dạng cách viết khác nhau và được thúc đẩy bởi những mục đích cơ bản khó hiểu. [32]

Phát hiện tin giả đòi hỏi kiến thức sâu rộng và đa dạng về thế giới. Đồng thời, bản thân tin giả thường bao gồm các chi tiết giật gân hay những truyền đạt tiêu cực [33]. Một mô hình phát hiện tin giả cần nhanh chóng phát hiện thông tin trên các khía cạnh nà

CHƯƠNG III. ỨNG DỤNG MÔ HÌNH NGÔN NGỮ LỚN CHO BÀI TOÁN PHÁT HIỆN TIN GIẢ

1. Phân tích bài toán


Mặc dù đã có nhiều tiến bộ, việc hiểu và mô tả tin giả vẫn đang là thách thức với các mô hình hiện tại. Phương pháp hiện tại thường khai thác các mô hình ngôn ngữ có bao gồm kiến trúc theo nhóm *Auto Encoding* được huấn luyện sơ bộ như *BERT*, *RoBERTa* [34] hay *T5* để hiểu nội dung tin tức và cung cấp các biểu diễn ngữ nghĩa cơ bản, cộng thêm các cơ sở tri thức làm phần bổ sung cho quá trình phát hiện. Tuy nhiên, những hạn chế về kiến thức của chúng làm ảnh hưởng đến hiệu suất chung của mô hình.

Các mô hình ngôn ngữ lớn hơn và hiện đại hơn được kì vọng sẽ có thể khắc phục được nhược điểm này. Mặc dù vậy, do số lượng tham số khổng lồ và sự hạn chế về phần cứng, ta không thể thực hiện tinh chỉnh như các mô hình ngôn ngữ nhỏ hơn mà chỉ có thể thực hiện các kỹ thuật như *In-context Learning* hay *Parameter Efficient Fine-Tuning* [35] [36]. Dù vậy, các nghiên cứu đã chứng minh việc này vẫn không hiệu quả bằng sử dụng một mô hình ngôn ngữ được tinh chỉnh hoàn toàn, mặc dù có khối lượng tham số khiêm tốn trong tác vụ phát hiện tin giả [32].

Thông qua phân tích các suy luận trung gian từ CoT được thực hiện trên LLM hiện đại đã chứng minh LLM với kiến trúc rất lớn vẫn có vai trò đáng kể. Nó có thể trở thành một cố vấn hiệu quả nhờ lượng tri thức khổng lồ và đa dạng của mình [32].

2. Mô hình đề xuất

Dựa trên những trình bày trước đó về sự ưu việt cùng sự hạn chế của LLM, chúng tôi đề xuất mô hình *Explanation-Guided Network* – EGN (mạng được định hướng bởi phân tích) cho bài toán phát hiện tin giả. Hình 2 là tổng quan về kiến trúc của EGN.



Hình 2. Tổng quan cấu trúc của EGN

Cho một item tin tức x cần được xác định tính chính xác. Đầu tiên, EGN sử dụng kỹ thuật prompting trên một LLM để thu được các lời giải thích về thường thức e_c và các lời giải thích về cảm xúc e_s . Tiếp theo, EGN mã hóa các văn bản x , e_s , e_c bằng một mô hình ngôn ngữ hiện đại. Cuối cùng, các vector ngữ nghĩa f_x , f_c , f_s từ quá trình mã hóa được tổng hợp và phân loại tại một bộ phân lớp.

2.1. Thu thập Explanation

Ở giai đoạn này, mô hình sử dụng kỹ thuật *Zero-shot CoT Learning* để tạo ra các bước suy luận logic về tính xác thực của tin tức từ 2 góc độ thường thức (*common sense*) và cảm xúc (*sentiment*). Mẫu *prompt* được sử dụng như sau:

Given the following message, predict its veracity. If it is more likely to be a real message, return 0; otherwise, return 1. Let's think step by step from the perspective of sentiment. Only target in [sentiment / common sense] aspect. Please refrain from providing ambiguous assessments such as undetermined. The message is: [mẫu tin x].

Ngoài ra, chúng tôi sử dụng kỹ thuật nhập vai [37] để tạo ngữ cảnh trong mẫu *prompt*:

You are master of analyst fake news by rationales.

Chúng tôi cố gắng thu thập các kết quả trả về chỉ từ 150 – 200 tokens nhằm đảm bảo độ tập trung của các lời giải thích vào một khía cạnh được yêu cầu.

2.2. Encoding và Representation

Chúng tôi triển khai 2 mô hình BERT riêng biệt làm phần mã hóa nội dung và mã hóa lời giải thích để thu được các đặc trưng ngữ nghĩa. Với mỗi item tin tức x và 2 giải thích e_c, e_s , các biểu diễn lần lượt là X, C, S tương ứng.

Content Encoder và *Explanation Encoder* được đóng băng tất các tầng của BertEncoder, ngoại trừ tầng cuối. Tầng này tham gia vào quá trình huấn luyện chung mô hình. Điều này đảm bảo mô hình thích ứng được với nội dung hoặc hướng dẫn đầu vào nhưng vẫn bao quát được các bước lập luận dưới nhiều góc độ không lường trước (dù vẫn thuộc một khía cạnh).

Với mỗi ma trận kết quả, mô hình sử dụng một Attentive Pooling, có bản chất là một MLP [38], để biến đổi ma trận thành vector. Attentive Pooling được biểu diễn như sau:

$$e_i = \sum \omega_j \cdot R_{i,j}$$

Với ω là trọng số có thể học của mạng MLP, R là ma trận biểu diễn ngữ nghĩa.

Vector e được chuẩn hóa sử dụng vector mask của biểu diễn ngữ nghĩa từ BERT Encoder. Vector f được tạo thành từ ma trận đầu vào R nhân với vector e :

$$f_i = \sum s_j \cdot R_{ij}$$

2.3. Final Classification

Các vector từng bước trên được tổng hợp để thu được một vector hợp nhất. Chúng tôi sử dụng mạng MLP với vai trò là bộ phân lớp. Với một item tin tức x có nhãn $y \in \{0,1\}$, chúng tôi tổng hợp các vector f_x, f_c, f_s với các trọng số khác nhau:

$$f_{cls} = \omega_x^{cls} \cdot f_x + \omega_c^{cls} \cdot f_c + \omega_s^{cls} \cdot f_s$$

Với ω^{cls} là các trọng số có thể được huấn luyện. f_{cls} là vector kết hợp được đưa vào một mạng MLP phân loại.

$$L_{CE} = CE(MLP(f_{cls}, y))$$

Hàm loss L_{CE} là một hàm cross-entropy loss [39].

3. Đánh giá

3.1. Cấu hình thực nghiệm

Nghiên cứu này thực hiện trên máy tính có cấu hình như sau:

- CPU: Xeon® E5-2695 v2
- VGA: 1x RTX 3090, VRAM: 24GB
- RAM: 258 GB

Nghiên cứu sử dụng mô hình GPT-3.5-turbo thông qua API do OpenAI cung cấp để thực hiện prompting trên LLM. Nghiên cứu sử dụng *bert-base-uncased* được cung cấp thông qua HuggingFace Hub để làm các Encoder trong quá trình Encoding.

3.2. Tập dữ liệu

Chúng tôi sử dụng 2 tập dữ liệu thuộc 2 lĩnh vực khác nhau để tiến hành thực nghiệm. Bảng 1 biểu diễn thông kê trên 2 tập dữ liệu.

GossipCop [40] là một bộ dữ liệu tin tức tiếng Anh tập trung vào tin đồn của người nổi tiếng. Chúng tôi tiến hành loại bỏ các mẫu tin trùng lặp để giảm thiểu việc ảnh hưởng đến quá trình huấn luyện.

Tập dữ liệu COVID-19 được thu thập từ [41]. Tập dữ liệu bao gồm 586 tin thật và 578 tin giả, là các bài báo và bài đăng trên mạng xã hội liên quan đến COVID-19. Các tin thật được thu thập từ Publishing, WHO, CDC, The New York Times... Các tin giả được thu thập từ các bài đăng trên mạng xã hội (Facebook) và các trang y tế khác. Chúng tôi thực hiện phân chia tập dữ liệu này để thuận tiện cho quá trình huấn luyện.

	Tập dữ liệu GossipCop			Tập dữ liệu COVID-19		
	Train	Valid	Test	Train	Valid	Test
Real	2,878	1,030	1,024	410	118	58
Fake	1,006	244	234	404	116	58
Total	3,884	1,274	1,258	814	234	116

Bảng 1. Thống kê thành phần tập dữ liệu GossipCop và COVID-19

3.3. Các phương pháp khác tham gia đánh giá

a. Long Short-term Memory

Long Short-term Memory (LSTM) là một loại mô hình recurrent neural network (RNN) đặc biệt, sử dụng các cổng quên và cập nhật để khắc phục tình trạng mất mát thông tin đối với các phụ thuộc dài. LSTM đã được chứng minh là có hiệu quả trong việc xử lý dữ liệu tuần tự, bao gồm cả văn bản. Trong lĩnh vực phát hiện tin giả, LSTM đã được sử dụng để phân tích nội dung tin tức và xác định xem đó là tin giả hay tin thật.

b. Gated Recurrent Unit

Gated Recurrent Unit (GRU) là một biến thể khác của RNN. GRU sử dụng các cổng cập nhật và cổng reset để kiểm soát luồng thông tin qua mạng, giúp mô hình ghi nhớ trong thời gian dài. Tương tự như LSTM, GRU cũng đã được sử dụng rộng rãi trong bài toán phát hiện tin giả.

c. BERT

Để thực hiện tác vụ phân loại dựa trên các biểu diễn ngữ nghĩa của BERT, chúng tôi thêm một lớp MLP và tiến hành tinh chỉnh trên dữ liệu của tập train.

3.4. Các chỉ số đánh giá

a. Accuracy

Độ chính xác (accuracy) là tỉ lệ giữa số điểm được dự đoán đúng và tổng số điểm trong tập dữ liệu kiểm thử.

$$accuracy(y, \hat{y}) = \frac{1}{n_{samples}} \sum_{i=0}^{n_{samples}-1} 1(\hat{y}_i = y_i)$$

Với $1(x)$ là hàm chỉ thị (Indicator function).

b. F1-score

F1-score là trung bình điều hòa giữa precision và recall.

$$F1 = \frac{2 * TP}{2 * TP + FP + FN}$$

Với TP là số mẫu true positives, FN là số mẫu false negatives, FP là số mẫu false positives.

3.5. Kết quả thực nghiệm

Bảng 2 và Bảng 3 lần lượt trình bày kết quả thực nghiệm trên tập dữ liệu GossipCop và COVID-19. Do tập dữ liệu GossipCop bị mất cân bằng, ngoài accuracy chúng tôi sử dụng thêm F1 score làm chỉ số đánh giá với tập GossipCop do sự mất cân bằng dữ liệu giữa 2 lớp.

Model	macF1	Accuracy	F1 real	F1 fake
GPT-3.5-turbo*	70.2%	81.3%	88.4%	51.9%
BERT*	76.5%	86.2%	91.6%	61.5%
EGN (đề xuất)	79.12%	88.49%	93.27%	64.97%

Bảng 2. Kết quả thực nghiệm mô hình EGN trên tập dữ liệu GossipCop

Các kết quả với dấu sao (*) được lấy từ [32].

Model	Test accuracy
GRU*	86.12%
LSTM*	83.73%
BERT	88.79%
EGN (đề xuất)	97.41%

Bảng 3. Kết quả thực nghiệm mô hình EGN trên tập dữ liệu COVID-19

Các kết quả với dấu (*) được lấy từ [42].

3.6. Đánh giá kết quả

Kết quả thực nghiệm cho thấy mô hình của chúng tôi ưu việt hơn so với các phương pháp khác (đã được trình bày trong kết quả thực nghiệm). Với tập dữ liệu GossipCop, mô hình của chúng tôi vượt qua hiệu suất của phương pháp tiêu chuẩn 2.62% ở macro F1-score, 2.29% với accuracy. Với tập dữ liệu COVID-19, mô hình của chúng tôi vượt qua hiệu suất của phương pháp tiêu chuẩn là BERT (được tinh chỉnh) đến 8.62%.

CHƯƠNG IV. KẾT LUẬN

1. Kết quả đạt được

Nghiên cứu này đã đạt được 2 kết quả chính như sau:

- **Thứ nhất**, nghiên cứu đã thành công trình bày một tổng quan toàn diện về mô hình ngôn ngữ lớn (LLM), bao gồm kiến trúc, cơ chế hoạt động, khả năng và các ứng dụng tiềm năng của LLM trong nhiều lĩnh vực khác nhau.
- **Thứ hai**, nghiên cứu đã đề xuất và triển khai thành công một mô hình mới dựa trên LLM để giải quyết bài toán phát hiện tin giả. Mô hình này tận dụng khả năng suy luận và phân tích ngữ nghĩa mạnh mẽ của LLM thông qua kỹ thuật *Prompt Chain-of-Thought (CoT) zero-shot* và mã hóa BERT. Kết quả thực nghiệm cho thấy mô hình đề xuất đạt hiệu suất vượt trội so với các mô hình phát hiện tin giả khác đã có, chứng minh tính hiệu quả và tiềm năng ứng dụng của LLM trong lĩnh vực này.

2. Hướng nghiên cứu tiếp theo

Nghiên cứu này đã mở ra nhiều hướng nghiên cứu tiếp theo đầy tiềm năng trong việc khai thác và ứng dụng LLM, đặc biệt trong tác vụ phát hiện tin giả, bao gồm:

- **Tích hợp các hệ thống tri thức:** Tích hợp các hệ thống kiến thức bên ngoài vào LLM bao gồm đồ thị tri thức (*knowledge graph*), cơ sở tri thức (*knowledge base*) hoặc thông tin từ các nguồn đáng tin cậy để tăng cường khả năng suy luận của LLM.
- **Tối ưu hóa kỹ thuật prompting:** Tiếp tục nghiên cứu và phát triển kỹ thuật prompt nhằm tạo ra các suy luận sâu sắc và chính xác hơn.
- **Xây dựng hệ thống phát hiện tin giả theo thời gian thực:** Phát triển các hệ thống có khả năng phát hiện tin giả nhanh chóng và chính xác trên các luồng dữ liệu lớn, chẳng hạn như mạng xã hội hoặc các trang tin tức trực tuyến.

TÀI LIỆU THAM KHẢO

- [1] Rumelhart, et al, "Learning internal representations by error propagation, parallel distributed processing, explorations in the microstructure of cognition, ed. de rumelhart and j. mcclelland. vol. 1. 1986," *Biometrika*, vol. 71, no. 6, pp. 599-607, 1986.
- [2] Bahdanau, Dzmitry and Cho, Kyunghyun and Bengio, Yoshua, "Neural machine translation by jointly learning to align and translate," *arXiv preprint arXiv:1409.0473*, 2014.
- [3] Sutskever, Ilya, et al, "Sequence to sequence learning with neural networks," *Advances in neural information processing systems*, vol. 27, 2014.
- [4] Schuster, Mike and Paliwal, Kuldeep K, "Bidirectional recurrent neural networks," *IEEE transactions on Signal Processing*, vol. 45, no. 11, pp. 2673-2681, 1997.
- [5] S. Hochreiter, "The vanishing gradient problem during learning recurrent neural nets and problem solutions," *International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems*, vol. 6, no. 2, pp. 107-116, 1998.
- [6] Hochreiter, Sepp, et al, "Long short-term memory," *Neural computation*, vol. 9, no. 8, pp. 1735-1780, 1997.
- [7] Chung, Junyoung, et al, "Empirical evaluation of gated recurrent neural networks on sequence modeling," *arXiv preprint arXiv:1412.3555*, 2014.
- [8] Ashish Vaswani, et al, "Attention is All you Need," *Advances in neural information processing systems*, vol. 30, 2017.
- [9] Kiros, Ryan, et al, "Skip-thought vectors," *Advances in neural information processing systems*, vol. 28, 2015.
- [10] LeCun, Yann, et al, "Backpropagation applied to handwritten zip code recognition," *Neural computation*, vol. 1, no. 4, pp. 541-551, 1989.

- [11] He, Kaiming, et al, "Deep residual learning for image recognition," *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 770-778, 2016.
- [12] Ba, Jimmy Lei, et al, "Layer normalization," *arXiv preprint arXiv:1607.06450*, 2016.
- [13] Han, Xu, et al, "Pre-trained models: Past, present and future," *AI Open*, vol. 2, pp. 225-250, 2021.
- [14] OpenAI, Inc., "OpenAI," OpenAI, Inc., 2015. [Online]. Available: <https://openai.com/>. [Accessed 30 7 2024].
- [15] T. Quân Thành, "Tiền huấn luyện và các mô hình ngôn ngữ lớn dựa trên transformer," in *Các mô hình học sâu nâng cao*, Thành phố Hồ Chí Minh, Nhà xuất bản Đại học quốc gia TP. Hồ Chí Minh, 2023, p. 59.
- [16] Raffel, Colin, et al, "Exploring the limits of transfer learning with a unified text-to-text transformer," *Journal of machine learning research*, vol. 21, no. 140, pp. 1-67, 2020.
- [17] Chung, Hyung Won, et al, "Scaling instruction-finetuned language models," *Journal of Machine Learning Research*, vol. 25, no. 70, pp. 1-53, 2024.
- [18] Devlin, Jacob, et al, "Bert: Pre-training of deep bidirectional transformers for language understanding," *arXiv preprint arXiv:1810.04805*, 2018.
- [19] Zhu, Yukun, et al, "Aligning books and movies: Towards story-like visual explanations by watching movies and reading books," in *Proceedings of the IEEE international conference on computer vision*, 2015, pp. 19-27.
- [20] P. Nayak, "Understanding searches better than ever before," 25 10 2019. [Online]. Available: <https://blog.google/products/search/search-language-understanding-bert/>. [Accessed 30 7 2024].
- [21] Radford, Alec, et al, "Improving language understanding by generative pre-training," San Francisco, CA, USA, San Francisco, 2018.
- [22] Brown, Tom, et al, "Language models are few-shot learners," *Advances in neural information processing systems*, vol. 33, pp. 1877-1901, 2020.

- [23] Min, Sewon, et al, "Rethinking the Role of Demonstrations: What Makes In-Context Learning Work?," 2022.
- [24] Wei, Jason, et al, "Chain-of-thought prompting elicits reasoning in large language models," *Advances in neural information processing systems*, vol. 35, pp. 2482435-24837, 2022.
- [25] Kojima, Takeshi, et al, "Large language models are zero-shot reasoners," *Advances in neural information processing systems*, vol. 35, pp. 22199-22213, 2022.
- [26] Zhao, Wayne Xin, et al, "A Survey of Large Language Models," *arXiv preprint arXiv:2303.18223*, 2023.
- [27] Marc Fisher, John Woodrow Cox, and Peter Hermann, "Pizzagate: From rumor, to hashtag, to gunfire in D.C.," *The Washington Post*, 2016.
- [28] CHEQ, "The economic cost of bad actors on the internet.," CHEQ, 2019. [Online]. Available: https://info.cheq.ai/hubfs/Research/THE_ECONOMIC_COST_Fake_News_final.pdf. [Accessed 30 7 2024].
- [29] S. B. Naeem and R. Bhatti, "The Covid-19 ‘infodemic’: a new front for information professionals," *Health Information & Libraries Journal*, vol. 37, no. 3, pp. 233-239, 2020.
- [30] Shu, Kai, et al, "Fake news detection on social media: A data mining perspective," *ACM SIGKDD explorations newsletter*, vol. 19, no. 1, pp. 22-36, 2017.
- [31] Hu, Linmei, et al, "Deep learning for fake news detection: A comprehensive survey," *AI open*, pp. 133-155, 2022.
- [32] Hu, B., Sheng, Q., Cao, J., Shi, Y., Li, Y., Wang, D., & Qi, P., "Bad actor, good advisor: Exploring the role of large language models in fake news detection," *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 38, no. 20, pp. 22105-22113, 2024.
- [33] Bhutani, Bhavika, et al, "Fake news detection using sentiment analysis," in *2019 twelfth international conference on contemporary computing (IC3)*, IEEE, 2019, pp. 1-5.

- [34] Liu, Yinhan, et al, "Roberta: A robustly optimized bert pretraining approach," *arXiv preprint arXiv:1907.11692*, 2019.
- [35] Hu, Edward J, et al, "Lora: Low-rank adaptation of large language models," *arXiv preprint arXiv:2106.09685*, 2021.
- [36] Lester, Brian, et al, "The power of scale for parameter-efficient prompt tuning," *arXiv preprint arXiv:2104.08691*, 2021.
- [37] Liu, Yi, et al, "Jailbreaking chatgpt via prompt engineering: An empirical study," *arXiv preprint arXiv:2305.13860*, 2023.
- [38] F. Rosenblatt, "The perceptron: a probabilistic model for information storage and organization in the brain.," *Psychological review*, vol. 65, no. 6, p. 386, 1958.
- [39] I. J. Good, "Rational decisions," *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 14, no. 1, pp. 107-114, 1952.
- [40] Shu, Kai, et al, "Fakenewsnet: A data repository with news content, social context, and spatiotemporal information for studying fake news on social media," *Big data*, vol. 8, no. 3, pp. 171-188, 2020.
- [41] L. Susan, "Explore COVID-19 infodemic," 28 5 2020. [Online]. Available: <https://towardsdatascience.com/explore-covid-19-infodemic-2d1ceaae2306>. [Accessed 30 7 2024].
- [42] Iwendi, Celestine, et al, "Covid-19 fake news sentiment analysis," *Computers and electrical engineering*, vol. 101, 2022.